

Identificación usando DAGs

Ricardo Pasquini

Universidad Austral

1/6/2026

Intro

- ▶ Vamos a analizar la utilización de un DAG para inferir causalidad a partir de datos observados (no-experimentales).
- ▶ Nuestro punto de partida es el de siempre: en una situación de datos observacionales, diferenciar a un resultado en relación a una cierta política o tratamiento da como resultado algo que no necesariamente es el efecto de la política. Esa diferencia no solo devuelve el efecto en sí, sino que también podría encubrir diferencias preexistentes.
- ▶ La novedad aquí será explicitar cuáles son los factores que sesgan esta diferencia, y analizar qué método es necesario para recuperar una estimación libre de sesgos.

Motivación: ¿La publicidad aumenta las ventas?


- ▶ Un gerente de marketing observa que las sucursales con mayor gasto en publicidad también tienen mayores ventas y concluye que la publicidad impulsa las ventas.
- ▶ **¿Es correcta esta conclusión?**
- ▶ No necesariamente: las sucursales *más grandes* tanto invierten más en publicidad *como* tienen más ventas, independientemente del efecto real de la publicidad.
- ▶ A lo largo de esta clase veremos cómo *confounders*, colisionadores y mediadores pueden hacer que una correlación sea engañosa — y cómo los DAGs nos dan un marco sistemático para identificar qué controlar (y qué no).

¿Qué es un DAG?

- ▶ Pearl y Mackenzie (2018) proponen utilizar a los gráficos causales para identificar cómo realizar un análisis que permita recuperar un efecto causal.
- ▶ Un gráfico permitirá identificar qué controles deberían agregarse al análisis y qué controles no.
- ▶ El gráfico directo acíclico, nos permite hacer una representación de cómo los constructos teóricos interactúan causalmente.
- ▶ Podemos también pensar a cada nodo como una variable y las flechas representan cómo se ven causalmente afectadas.
- ▶ El grafo debe incluir todas las relaciones causales que suponemos existen, y debieramos armarlo en base a nuestra experiencia y conocimiento de la literatura.

Ejemplo de un DAG

- ▶ Tomemos el siguiente típico ejemplo de existente de un *confounder*:
- ▶ El supuesto es que Z tiene un efecto sobre X y sobre Y .
- ▶ La flecha entre X e Y representa al efecto que quisieramos identificar.
- ▶ Esta situación se corresponde con una típica situación donde la correlación de X con Y no es necesariamente indicativa del efecto causal, porque Z sesga esa relación: nótese que el efecto de Z podría hacernos ver un efecto aún en un caso de que no lo haya.
- ▶ Sabemos que resolvemos el problema si controlamos por Z .



Aplicación: Publicidad y Ventas

- ▶ Volvamos al ejemplo del gerente de marketing. Identifiquemos las variables:
 - ▶ X = Gasto en publicidad de la sucursal
 - ▶ Y = Ventas de la sucursal
 - ▶ Z = Tamaño de la sucursal
- ▶ Las sucursales más grandes tienen mayor presupuesto publicitario **y** más clientes, con independencia del efecto de la publicidad. Controlar por tamaño (Z) aísla el efecto genuino.
- ▶ **Otro ejemplo análogo:**
 - ▶ X = Participación en programa de capacitación
 - ▶ Y = Productividad del empleado
 - ▶ Z = Ambición del empleado: los más ambiciosos buscan más capacitación **y** rinden mejor de manera independiente.

Sistematizando el análisis de un DAG

- ▶ La propuesta de identificación de Pearl, consiste en identificar todos los posibles senderos desde X a Y . Un sendero es un camino a través de los nodos conectados sin tener en cuenta la direccionalidad de las flechas.
- ▶ La idea es que los posibles senderos pueden introducir confusión en la relación, y por esta razón nuestro análisis estará enfocado en "bloquear" esos senderos. Esos senderos se los llama "back-door paths".
- ▶ Por ejemplo, en el caso anterior, tenemos dos senderos: i) el sendero de interés $X \Rightarrow Y$ y ii) el sendero que genera la confusión: $X \Leftarrow Z \Rightarrow Y$.


Analizando el DAG

La direccionalidad de las flechas en un sendero tiene implicancias importantes. Podemos distinguir distintos casos de acuerdo a como llegan las flechas a un nodo intermedio.

- ▶ Una *cadena* tiene la forma $X \Rightarrow Z \Rightarrow Y$. Controlar por Z previene que detectemos una relación entre X e Y . Por lo tanto no quisieramos controlar por Z cuando hay una cadena.
- ▶ En una *bifurcación* $X \Leftarrow Z \Rightarrow Y$ controlar por Z previene que X e Y mantengan una relación espúrea generada por Z . Por lo tanto quisieramos controlar por Z de manera evitar una relación espúrea.
- ▶ En un *colisionador* $X \Rightarrow Z \Leftarrow Y$, X e Y son independientes, pero si se empieza a controlar Z , entonces se observará una relación entre X e Y . Por lo tanto, no quisieramos controlar por un colisionador.

Juegos para De-confundir

Juego 2



Juegos para De-confundir

Juego 2


- ▶ No es necesario controlar por nada.
- ▶ Controlar por A sería una mala idea, ya que habilitaría el sendero $X \Rightarrow A \Leftarrow B \Rightarrow Y$.
- ▶ Notar que controlar por A y B simultáneamente resolvería el problema, pero no era necesario controlar por nada en primer lugar.

Juego 2: Aplicación de negocio

- ▶ Identifiquemos las variables:
 - ▶ **X** = Adopción de trabajo remoto
 - ▶ **Y** = Rentabilidad de la empresa
 - ▶ **B** = Condiciones del mercado externo (causa tanto mayor rentabilidad como mayor satisfacción)
 - ▶ **A** = Satisfacción de los empleados (*colisionador*: recibe flechas de X y de B)
- ▶ Sin controles, no hay sendero de puerta trasera abierto: la correlación entre trabajo remoto y rentabilidad refleja solo el efecto causal.
- ▶ **Error típico**: un analista agrega la satisfacción al modelo “porque es relevante”. Esto abre el sendero $X \rightarrow A \leftarrow B \rightarrow Y$: el trabajo remoto ahora aparece correlacionado con la rentabilidad a través de las condiciones de mercado.

Juegos para De-confundir

Juego 3 "M-Bias"



Juegos para De-confundir

Juego 3 "M-Bias"


- ▶ No es buena idea controlar por B
- ▶ Si lo hago, entonces también tengo que controlar por A y C

M-Bias: Aplicación de negocio

- ▶ Identifiquemos las variables:
 - ▶ **X** = Participación en programa de capacitación
 - ▶ **Y** = Desempeño del empleado
 - ▶ **A** = Ambición del empleado (causa X: los ambiciosos se capacitan; y causa B: los ambiciosos son promovidos)
 - ▶ **C** = Calidad del manager (causa Y: buenos managers mejoran el desempeño; y causa B: buenos managers promueven a sus equipos)
 - ▶ **B** = Promoción previa (*colisionador* de A y C)
- ▶ **Error típico:** un analista agrega “fue promovido” como control, creyendo que captura mérito previo. Esto abre el sendero $X \leftarrow A \rightarrow B \leftarrow C \rightarrow Y$ y sesga la estimación del efecto de la capacitación.

Juegos para De-confundir

Juego 4




Juegos para De-confundir

Juego 4

- ▶ No es necesario incorporar controles pues B es un colisionador.
- ▶ Controlar por B es una mala idea.
- ▶ Si controlamos por B, tambien tendremos que controlar por A para bloquear nuevamente el sendero.
- ▶ Controlar por E es una mala idea, ya que vamos a capturar el efecto que X tiene sobre Y.

Juegos para De-confundir

Juego 5




Un ejemplo reciente publicado en *Science*

- ▶ Güllich et al. (2025) estudian si los mejores performers jóvenes son los mismos que alcanzan el rendimiento de cúspide adulto.
- ▶ Analizan muestras de campeones olímpicos, premios Nobel, grandes maestros de ajedrez y músicos de élite.
- ▶ **Hallazgo:** dentro de cada muestra de élite, rendimiento temprano y rendimiento adulto se correlacionan **negativamente**.
- ▶ **Conclusión de los autores:** distintos mecanismos causan el rendimiento temprano y el adulto — la especialización temprana sería contraproducente.
- ▶ **El problema:** la correlación negativa es un artefacto del diseño muestral, no un hallazgo causal.

El DAG del problema

- ▶ Tanto el rendimiento temprano (X) como el adulto (Y) causan la selección en la muestra de élite (Z): Z es un colisionador.
- ▶ Al estudiar solo élites, los autores condicionan sobre Z sin advertirlo, abriendo una asociación espúrea negativa entre X e Y .



- ▶ X = Rendimiento temprano Y = Rendimiento adulto
- ▶ Z = Selección en muestra de élite (colisionador) U = Talento/apoyo (latente)

La lección

- ▶ En la población completa, X e Y se correlacionan **positivamente** a través de U (talento, entrenamiento, apoyo).
- ▶ Dentro de la muestra de élite (condicionando sobre Z), tener alto rendimiento temprano “explica” parte del acceso a la élite, haciendo que el rendimiento adulto parezca menor — paradoja de Berkson.
- ▶ Una crítica metodológica (Nivard, 2025) demostró que el hallazgo de Güllich et al. es probablemente un artefacto, no un descubrimiento causal.